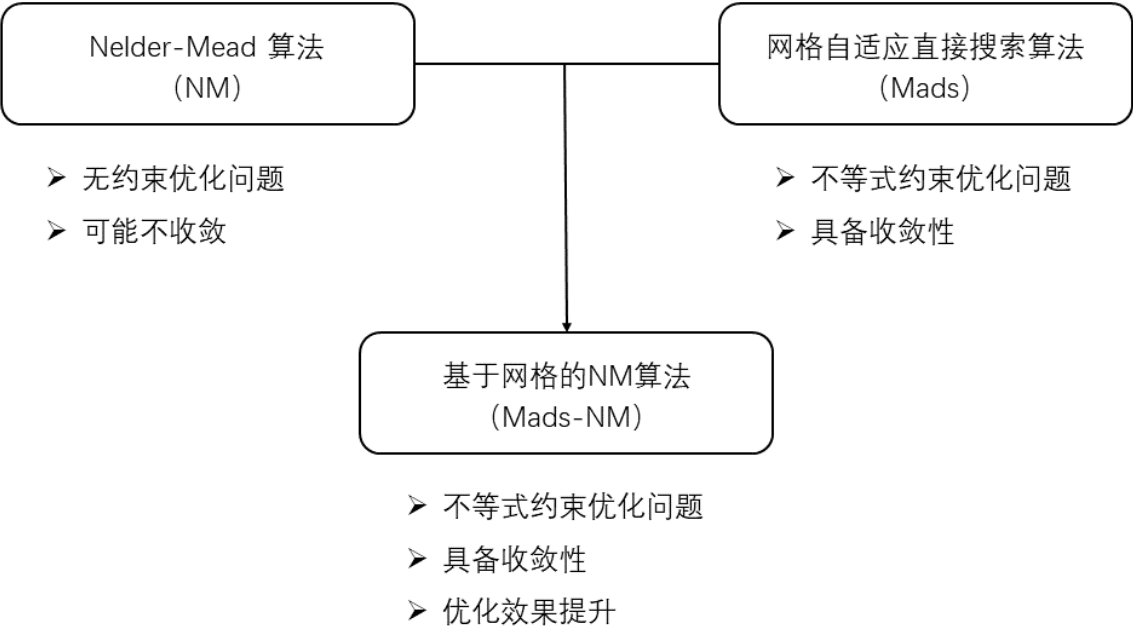


基于网格的NM不等式约束优化算法[1]总结报告

侯力广 521070910043

1.引言

在黑盒优化问题中：Nelder-Mead(NM)算法是一种处理无约束优化问题的算法，通过不断替换单纯性中最差的点来实现下降，但无法保证算法的收敛性；网格自适应方向搜索(Mads)算法是一种常用于处理不等式约束优化问题的算法，该方法有严谨的收敛性证明。在文献[1]中，作者将NM算法与Mads算法进行融合，提出的Mads-NM算法不仅可以解决不等式约束优化问题，具备严谨的收敛性证明，而且相较于NM和Mads均有明显的数值效果提升（文章脉络示意图如下）。



本次报告将分为四部分：NM无约束优化算法、Mads不等式约束优化算法、Mads-NM不等式约束优化算法，以及三种方法的效果比较。

2.NM无约束优化算法

2.1 目标问题

考虑无约束优化问题

$$\min_{x \in \mathbb{R}^n} f(x)$$

其中 $f: \mathbb{R}^n \mapsto \mathbb{R}$ 为目标函数。

2.2 基本概念

♠ **定义2.1 (控制):** $x, y \in \mathbb{R}^n$, 若 $f(x) < f(y)$, 称 x 控制 y , 记作 $x \prec y$.

♠ **定义2.2 (更旧):** 若算法中 x 在 y 之前生成, 则称 x 比 y 旧。定义函数 $\text{Older}: \mathbb{R}^n \times \mathbb{R}^n \mapsto \mathbb{R}$

$$\text{Older}(x, y) = \begin{cases} x & \text{若 } x \text{ 在 } y \text{ 之前生成} \\ y & \text{其他} \end{cases}$$

$\text{Older}(x, y)$ 会输出 x, y 中更旧的那个。

♠ **定义2.3 (更好):** 定义函数 $\text{Best}: \mathbb{R}^n \times \mathbb{R}^n \mapsto \mathbb{R}$

$$\text{Best}(x, y) = \begin{cases} x & \text{若 } x \prec y \\ y & \text{若 } y \prec x \\ \text{Older}(x, y) & \text{若 } f(x) = f(y) \end{cases}$$

易证 Best 具有传递性。若 $x = \text{Best}(x, y)$, 则称 x 比 y 更好。

♠ **定义2.4 (有序单纯形):** 将 \mathbb{R}^n 中 $n + 1$ 个仿射无关的点排序为 y^0, y^1, \dots, y^n , 使得 $y^{i-1} \prec y^i (i = 1, 2, \dots, n)$, 则集合

$$\mathbb{Y} = \{y^0, y^1, \dots, y^n\}$$

称为一个有序单纯形。

♠ **定义2.5 (区域):** 记 $\mathbb{Y} = \{y^0, y^1, \dots, y^n\}$ 为 \mathbb{R}^n 上的有一个有序单纯形, 测试点 $x \in \mathbb{R}^n$

- 若 $y^n \prec x$, 则 x 属于内缩区域;
- 其余情况, 若 $x \prec y^0$, 则 x 属于扩张区域;
- 其余情况, 若 x 至少掌控了 \mathbb{Y} 中的两个点, 则 x 属于反射区域;
- 其余情况, 若 x 掌控了 \mathbb{Y} 中的零或一个点, 则 x 属于外缩区域。

♠ **注释I:** 定义2.1-2.5仅针对无约束优化的目标问题2.1, 对于不等式约束优化的目标问题3.1和4.1, 我们会在下文给出新的定义。

2.3 NM算法思路

♣ 整体思路

NM算法于1965年被首次提出，其核心思路是：初始化一个有序单纯形并进行迭代，每一步迭代都要用一个更好的点来替换当前单纯形的最差点【详见NM-1】。随着迭代次数的增加，单纯形会变得越来越好，单纯形的最优点可能会收敛到目标问题的最优解【详见NM-2】。当迭代满足一定条件（例如相邻两次迭代的最优点函数值之差小于某个容忍值）时，迭代停止，将最终得到的单纯形的最优点作为目标问题的最优解。

♣ NM-1. 替换最差点的原则

NM算法的每一步迭代都会将有序单纯形 \mathbb{Y} 中最差的点 y^n 替换为一个更好的点。现做定义如下：

$$x^c = \frac{1}{n} \sum_{i=0}^{n-1} y^i$$

$$x^r = x^c + (x^c - y^n)$$

$$x^e = x^c + 2(x^c - y^n)$$

$$x^{oc} = x^c + \frac{1}{2}(x^c - y^n)$$

$$x^{ic} = x^c - \frac{1}{2}(x^c - y^n)$$

$$\gamma = \frac{1}{2}$$

中心


反射点

延长点

外缩点

内缩点

收缩参数



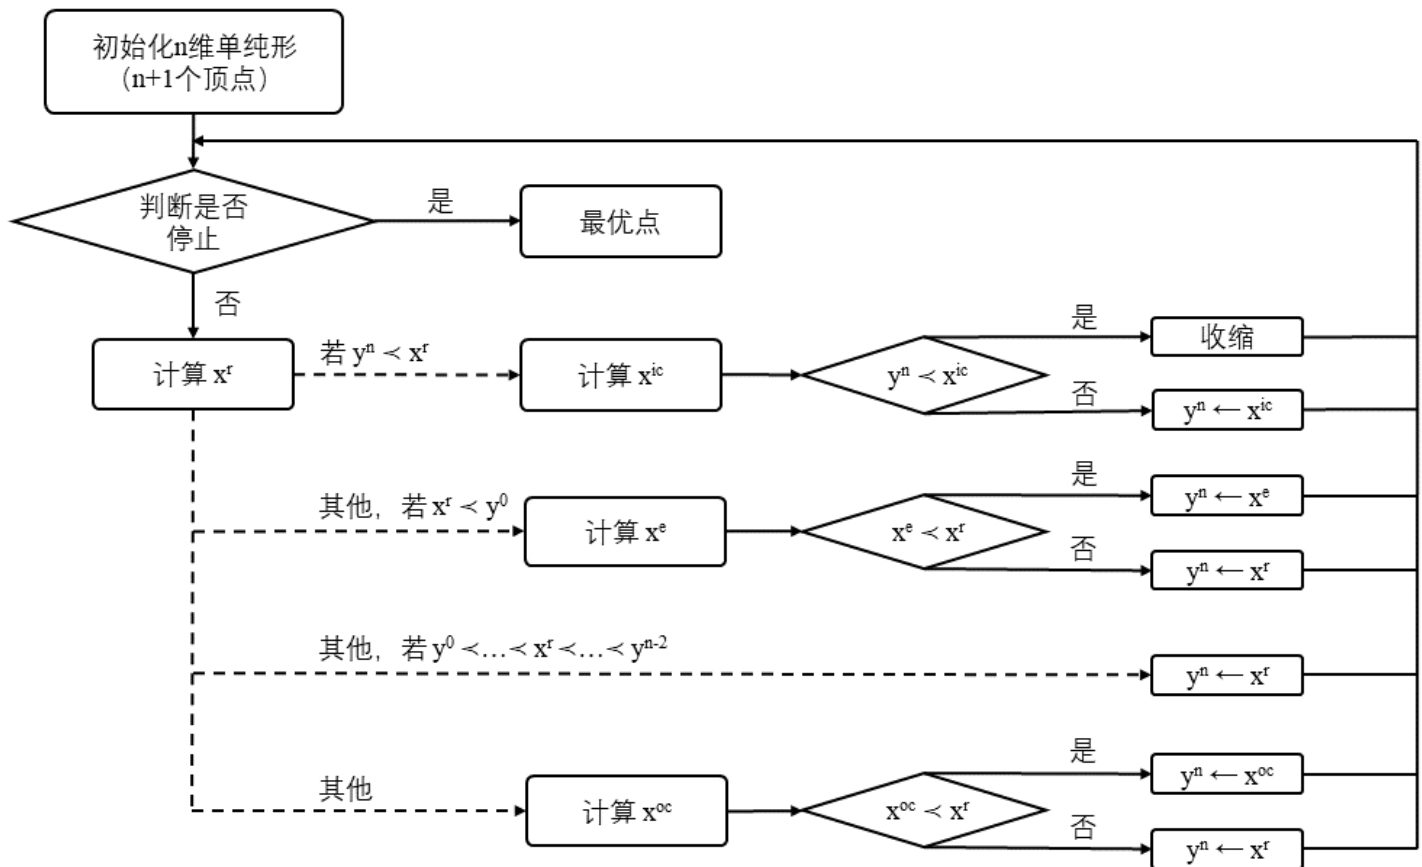
每一步迭代有五种替换方案，要么用 x^r, x^e, x^{oc}, x^{ic} 中的一个点替换 y^n ，要么将 y^1, y^2, \dots, y^n 向 y^0 的方向收缩，即：

$$\mathbb{Y} \leftarrow \{y^0, y^0 + \gamma(y^1 - y^0), \dots, y^0 + \gamma(y^n - y^0)\}. \quad (1)$$

针对不同的情况，NM会选取不同的替换点：

- 若 x^r 属于内缩区域且 x^{ic} 属于内缩区域，用公式(1)收缩；
- 若 x^r 属于内缩区域且 x^{ic} 不属于内缩区域，用 x^{ic} 替换 y^n ；
- 除上述情况，若 x^r 属于扩张区域，用 $\text{Best}(x^r, x^e)$ 替换 y^n ；
- 除上述情况，若 x^r 属于反射区域，用 x^r 替换 y^n ；
- 除上述情况，即 x^r 属于外缩区域，用 $\text{Best}(x^r, x^{oc})$ 替换 y^n ；

NM算法流程图：



♣ NM-2. 收敛性及相关研究

正如引言中所指出，NM算法未必能收敛至问题最优解。1998年McKinnon提出了一个 \mathbb{R} 上的光滑的严格凸函数[2]，在该函数上，NM算法产生的实验点序列无法接近唯一的最小值。1998-2012年，人们采用多种方法改进了NM算法，使其在某些限制条件下具备一定的收敛性[1]。本文[1] (2018)则是将NM算法融入了Mads算法，利用Mads的收敛性分析来确保算法收敛。

3.Mads不等式约束优化算法

3.1 目标问题

考虑不等式约束优化问题

$$\begin{aligned} \min_{x \in X \subset \mathbb{R}^n} & f(x) \\ \text{s.t.} \quad & c(x) \leq 0 \end{aligned}$$

其中 $f: X \mapsto \mathbb{R} \cup \infty$, $c: X \mapsto (\mathbb{R} \cup \infty)^m$, $c = (c_1, \dots, c_m)^T$, X 是 \mathbb{R}^n 的子集, c 可松弛, f 与 c 的平滑性无要求。

3.2 基本概念

♠ **定义3.1 (正张成集):** 给定向量空间 V , 若集合 S 的元素的非负线性组合可以张成 V , 则称 S 为 V 的正张成集。

♠ **定义3.2 (网格):** 设 $G \in \mathbb{R}^{n \times n}$ 为可逆矩阵, $Z \in \mathbb{Z}^{n \times p}$ 满足 Z 的列向量构成一个 \mathbb{R}^n 的正张成集, 设 $D = GZ$ 。

对于当前最优解 $x^k \in \mathbb{R}^n$, 以 x^k 为中心, 尺寸为 δ^k 的网格定义为

$$M^k = \{x^k + \delta^k D y \mid y \in \mathbb{N}^p\} \subset \mathbb{R}^n$$

其中 δ^k 称为网格尺寸参数。

♠ **定义3.3 (框架):** 设 $G \in \mathbb{R}^{n \times n}$ 为可逆矩阵, $Z \in \mathbb{Z}^{n \times p}$ 满足 Z 的列向量构成一个 \mathbb{R}^n 的正张成集, 设 $D = GZ$ 。

对于网格尺寸参数 δ^k , 取 Δ^k 满足 $\Delta^k \geq \delta^k$, 则以 x^k 为中心, 尺寸为 Δ^k 的框架定义为

$$F^k = \{x \in M^k \mid \|x - x^k\|_\infty \leq \Delta^k b\}$$

其中 $b = \max\{\|d'\|_\infty : d' \in \mathbb{D}\}$, \mathbb{D} 表示矩阵 D 的列向量构成的集合; Δ^k 称为框架尺寸参数。

♠ **定义3.4 (违约函数):** 设约束条件的索引集 $J = \{1, 2, \dots, m\}$, 定义违约函数

$$h(x) = \begin{cases} \sum_{j \in J} (\max\{c_j(x), 0\})^2 & \text{若 } x \in X \\ \infty & \text{其他} \end{cases}$$

$h(x)$ 总是非负的, $h(x) = 0 \iff x$ 在问题的可行域中, 即 $x \in \Omega = \{x \in X : c(x) \leq 0\}$.

♠ **定义3.5 (控制):** $x, y \in \mathbb{R}^n$, 若

- x, y 均可行, 且 $f(x) < f(y)$; 或
- x, y 均不可行, 且 $f(x) \leq f(y)$, $h(x) \leq h(y)$, 且至少有一个是严格不等号

则称 x 控制 y , 记作 $x \prec y$.

♠ **注释II:** 这里针对不等式约束优化的目标问题3.1给出了新的“控制”定义。

3.3 Mads算法思路

♣ 整体思路

Mads的每一步迭代由两个主要步骤组成：搜索和轮询。

- 搜索步骤可以使用各种策略来探索变量空间，一个精心设计的搜索步骤可以让算法避免落入局部最优解。
- 轮询步骤是在框架尺寸参数 Δ^k 所限制区域内的变量空间进行局部搜索，轮询步骤保证了算法的收敛性。

下面我们用一个例子直观地阐述Mads的搜索-轮询过程。对于

♣ Step2. 迭代：

Algorithm 2: The mesh adaptive direct search algorithm (Mads)

Given a user-defined set of starting point: $V^0 \subset \mathbb{R}^n$,
and initial mesh and poll size vectors: typically $\delta_i^0 = \Delta_i^0 = 1$ for $i = 1, 2, \dots, n$.

Set the iteration counter: $k \leftarrow 0$.

1. Search step (optional):

 | Launch the simulation on a finite set S^k of mesh points.
 | If successful, go to 3.

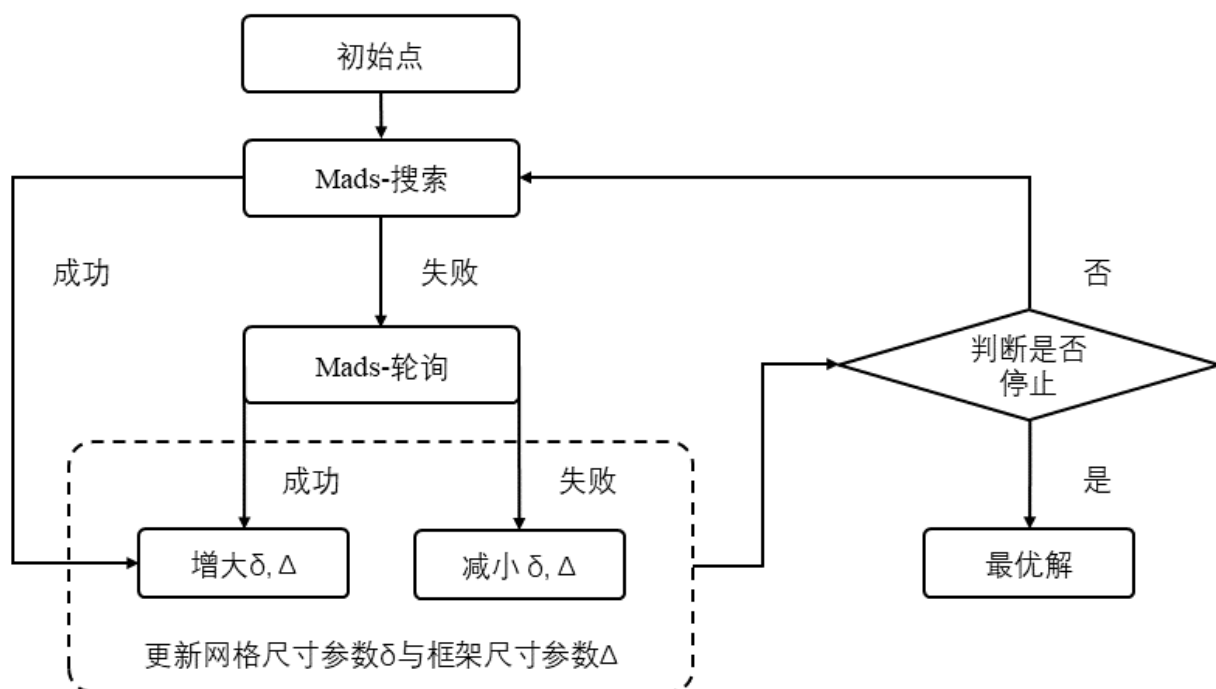
2. Poll step:

 | Launch the simulation on the set P^k of poll points.

3. Updates:

 | Update the cache V^{k+1} , the incumbent x^{k+1}
 | and the mesh and poll size vectors δ^{k+1} and Δ^{k+1} .
 | Increase the iteration counter $k \leftarrow k + 1$ and go to 1.

3.3 Mads算法总结:



参考文献

- [1]Audet, C., Tribes, C. Mesh-based Nelder–Mead algorithm for inequality constrained optimization. Comput Optim Appl 71, 331–352 (2018).
- [2]McKinnon, K.I.M.: Convergence of the Nelder–Mead simplex method to a nonstationary point. SIAMJ. Optim. 9(1), 148–158 (1998)